


Youtube - Statquest with Josh Starmer

Logistic Regression Details Pt 1: Coefficients

✳ Bu video lojistik regresyonun nasıl çalıştığını dair büyük resmi göstermeye çalışıyor.




✳ Özellikle her lojistik regresyonun sonucu olan "coefficients" leri nasıl belirlediğimizi ve nasıl yorumlayacağımızı öğreneceğiz.


Coefficients:

	Estimate	Std. Error	z-value	Pr(> z)
(Intercept)	-3.476	2.364	-1.471	0.1414
Weight	1.825	1.088	1.678	0.0934

✳ Kat sayıları hem continuous variable contextlerinde hem de discrete variable contextlerinde öğrenebiliriz. mutasyona uğramış gen veya değil



Main Ideas About Logistic Regression




Y eksenini bir faremin obez olma olasılığını veriyor. Faremin obez olmaması 0'dan, olması 1'e uzanıyor. Çizilen eğri verilen ağırlığa göre faremin obez olma olasılığını veriyor.


Ağırlığı arttıkça obez olma ihtimali daha yüksek.

* Lojistik regresyon belirli bir genelleştirilmiş lineer model türüdür. Genelleştirilmiş (generalized) lineer modeller, düzensiz lineer modellerin kavram ve yeteneklerinin bir genellemesidir.

Lineer Regresyon ve Lojistik Regresyon



Lineer regresyonda y ekseninde her türlü sayı yazılabilirken

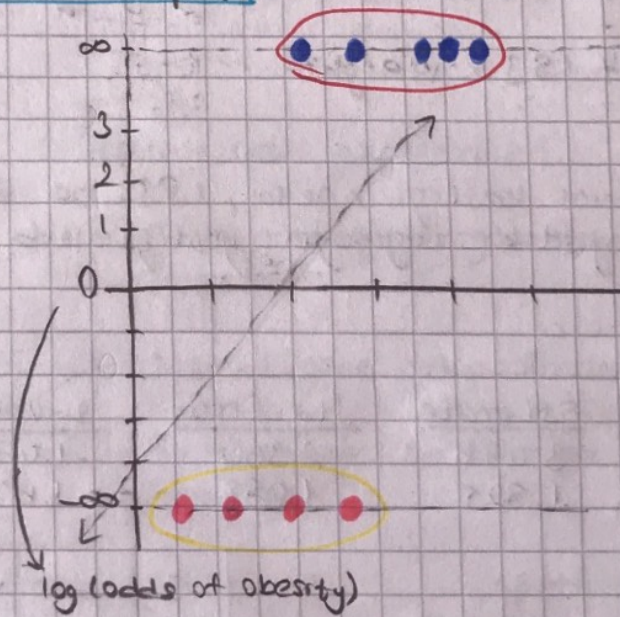
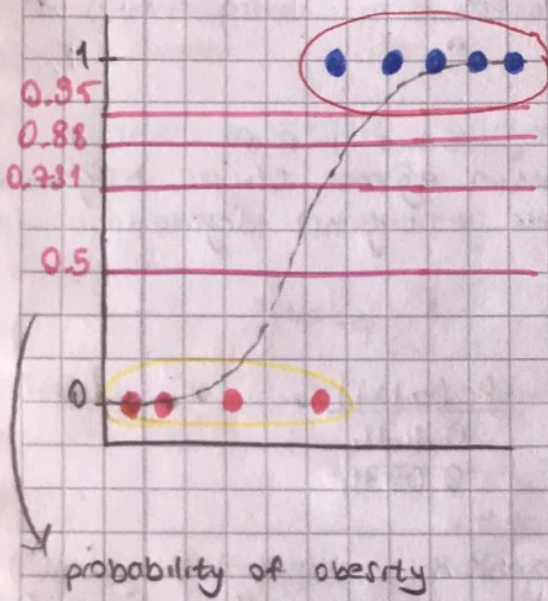


Kat sayıları ifade edebilmek için

Lojistik regresyonda y ekseninde 0 ile 1 arasında olasılık değerleri yatar.

* Bu sorunu aşmak için lojistik regresyondaki y eksenini "probability of obesity (obezite olasılığından)", "log (odds of obesity)" a dönüştürülür. Böylece, lineer regresyondaki gibi sonuçları + sonuçları gidebilir.

$$\log(\text{odds of obesity}) = \log\left(\frac{p}{1-p}\right) \text{ olarak ifade edebiliyorduk.}$$



$$\log\left(\frac{p}{1-p}\right) \rightarrow p=0.5 \text{ için } \log\left(\frac{0.5}{0.5}\right) = \log 1 = 0 \quad p=0.95 \text{ için } \log\left(\frac{0.95}{1-0.95}\right) = 3$$

$$p=0.7 \text{ için } \log\left(\frac{0.731}{1-0.731}\right) = \log(2.717) = 1$$

$$p=1 \rightarrow \log\left(\frac{1}{0}\right) = \log 1 - \log 0 = -\infty$$


$$p=0.88 \text{ için } \log\left(\frac{0.88}{1-0.88}\right) = \log(7.33) = 2$$

$$p=0 \rightarrow \log\left(\frac{0}{1}\right) = \log 0 - \log 1 = -\infty$$

Olasılığı 0.5 ile 1 arasında olan değerler yeni y ekseninde 0 ile ∞ arasında yerleştirken, olasılığı 0 ile 0.5 arasında olan değerler yeni y ekseninde 0 ile -∞ arasına yerleştiriyor.

Yeni y eksenimle dalgali olan line dat line'a dönüşmüş oldu.

Logistik regresyonu dalgali grafikte ifade ediyorken, kat sayıları $\log(\text{odds})$ cinsinden sunuluyor.



Kat sayıları ifade etmek için çıktığımız bu grafiği **maximum likelihood** ile yapıyoruz. Bu line'da da linear regresyon olduğu gibi;

$$y = -3.48 + 1.83 \times \text{weight}$$

-3.48 y eksenini kestirir nokta, 1.83 ise doğrunun eğimi oluyor. Doğrunun kat sayıları, **logistik regresyon** yaptığımızda elde ettiğimiz değerlerdir.


Coefficients:

	Estimate	Std. Error	z-value	Pr(> z)
(Intercept)	-3.476	2.364	-1.471	0.1414
weight	1.825	1.088	1.678	0.0934

→ İlk kat sayı $\text{weight}=0$ olduğundaki y eksenini kesen değerdir. Yani $\text{weight}=0$ olduğunda $\log(\text{odds of obesity}) = -3.476$.

$$-3.476 / 2.364 = -1.471$$

→ z-value: tahmin edilen kat sayı değerinin standart hataya oranıdır. Başka bir deyişle, standart bir normal eğri üzerinde tahmin keşmelemin 0'dan uzak olduğu standart sapmaların sayısıdır (odds ratio videolarındaki Wald Test)




0'dan 2 standart hata uzaklığından daha az bir uzaklıkta (-1.471) olduğu için, istatistiksel olarak bunun anlamlı olmadığını söyleyebiliriz. Bu da p-value'nun (0'dan 1.471 standart sapma daha uzak olan standart eğimin altında kalan alan) büyük olduğunu gösteriyor.

→ İkinci kat sayı eğim. Her bir günlük artışı için log (odds of obesity) 1.825 artar.

Aynı şekilde weightın katsayısı için de, standart hata sapmalarının sayısı 2'den daha az olduğu için (1.678) istatistiksel olarak anlamlı değildir. Bu da büyük p-value değerini gösterir.

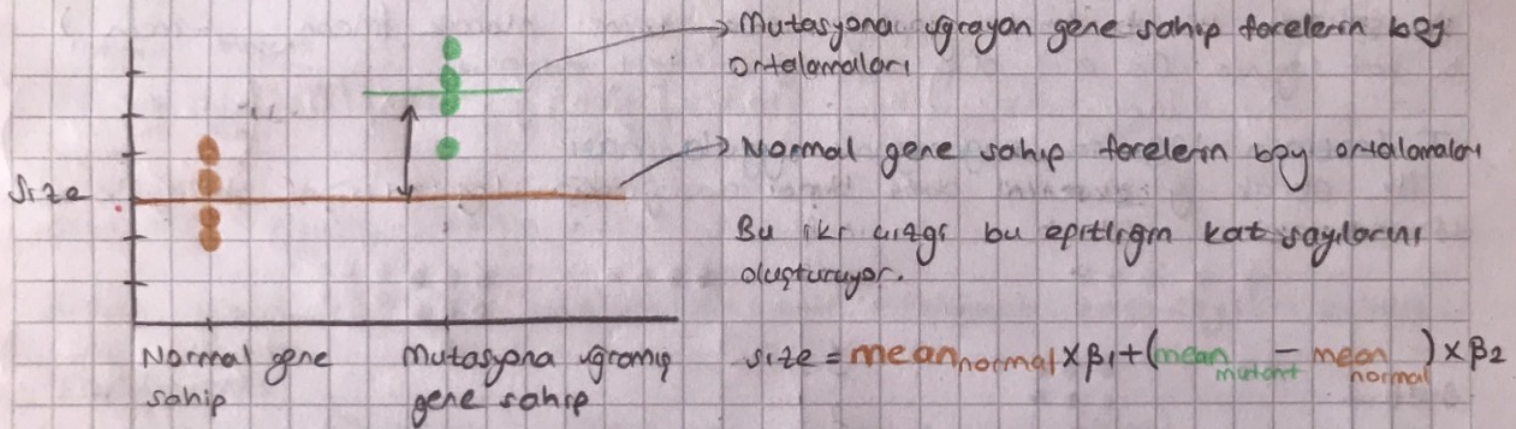
Şimdiye kadar obeziteyi tahmin etmek için sürekli değişken olarak weightı kullanmıştık.

Discrete Variable Kullanarak Obeziteyi Tahmin Etmek



Bu tür bir lojistik regresyon, lineer modeller kullanılarak bir t-testinin yapılmasına çok benzer.

Lineer modelleri kullanarak t-testini nasıl yapıyoruz?



Buna sonra, gen normal veya mutasyona uğramış verilerine sahip olan bir forem boyutunu tahmin etmek için bu denklemin bir design matrix ile eleştiriyoruz.

Design matrix

1	0
1	0
1	0
1	0
1	1
1	1
1	1
1	1

$$size = mean_{normal} \times \beta_1 + (mean_{mutant} - mean_{normal}) \times \beta_2$$

İlk column β_1 'in değerlerine karşılık geliyor ve ilk katsayı $mean_{normal}$ 'i aktive ediyor

İkinci column β_2 'nin değerlerine karşılık geliyor ve ikinci katsayı $(mean_{mutant} - mean_{normal})$ 'i aktive ediyor. Aktive etmekten kastımız 0 veya 1 olması β_1/β_2 'nin.

İlk row için (1-0) normal gene sahip bir foreye denk gelir.

Size'ini tahmin etmek için β_1 yerine 1, β_2 yerine 0 yazıyoruz.

$$size = mean_{normal} \times 1 + (mean_{mutant} - mean_{normal}) \times 0$$

$$size = mean_{normal} \text{ buluruz.}$$

Has Normal Gene Has Mutated Gene

(1-1) rowu mutasyona uğramış gene sahip bir foreye denk gelir. Fore'nin boyunu tahmin etmek için β_1 yerine 1, β_2 yerine 1 yerleştiriyoruz.

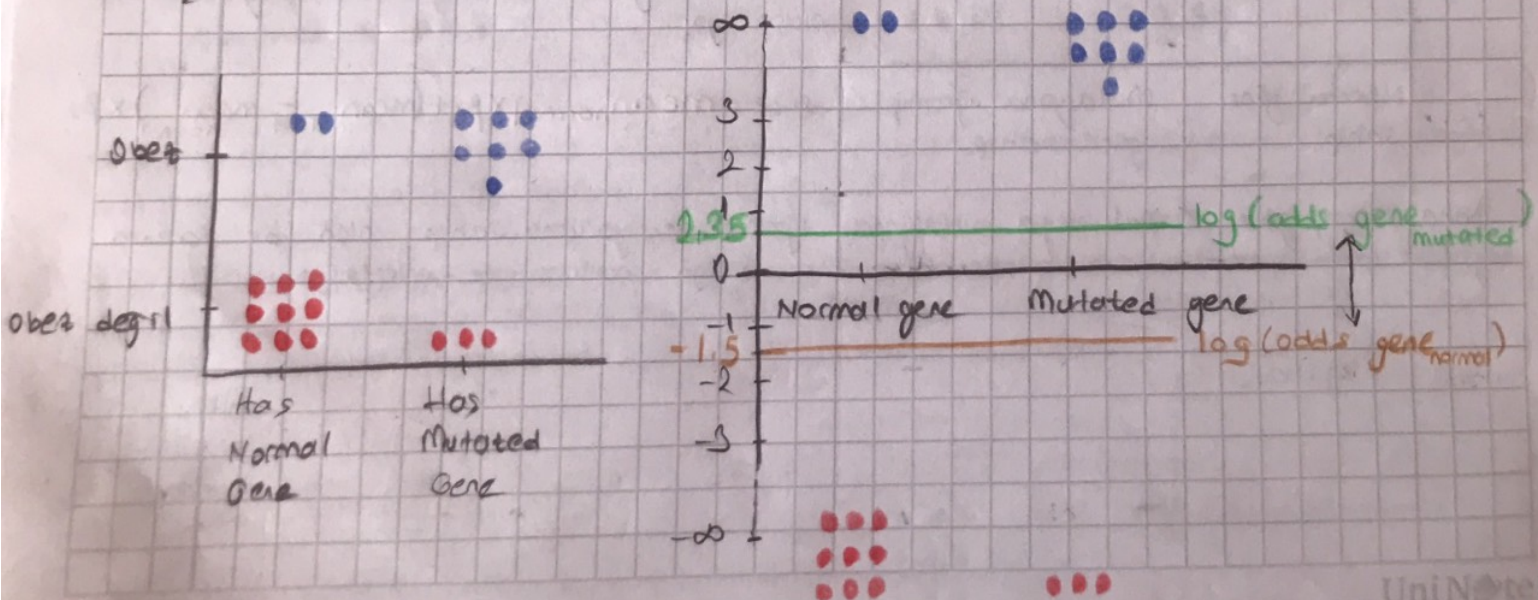
$$size = mean_{normal} \times 1 + difference_{mutant-normal}$$

$$size = mean_{normal} + (mean_{mutant} - mean_{normal})$$

Bu şekilde bir t testi yaptığımızda, temel olarak $(mean_{mutant} - mean_{normal})$ bu katsayının 0'da ept olup olmadığını test ediyoruz.

T testinin logaritmik regresyona uygulanması

İlk olarak y eksenini obez olma olasılığından $\log(\text{odds of obesity})$ 'e dönüştürmek



Şimdi verileri iki değeriye ait ediyoruz. İlk değeri için "Normal Gen" verilerini alıyoruz. ve normal gene sahip bireyler için $\log(\text{odds of obesity})$ hesaplamak için kullanıyoruz. Buna $\log(\text{odds gene normal})$ adını verdik.

$$\log\left(\frac{2}{9}\right) = \log(0.22) = -1.5$$

hüma:

Daha sonra mutasyona uğramış gene sahip bireyler için $\log(\text{odds of obesity})$ hesaplıyoruz. Bunu da $\log(\text{odds gene mutated})$ olarak isimlendirdik.

maui

$$\log\left(\frac{7}{3}\right) = \log(2.33) = 0.85$$

kırmızı

Bu iki değeri; $\text{size} = \log(\text{odds gene normal}) \times \beta_1 + (\log(\text{odds gene mutated}) - \log(\text{odds gene normal})) \times \beta_2$

bu eşitlikteki kat sayıları şekillendirmek için bir araya gelir. $\times \beta_2$

Bu eşitliği şu şekilde tekrar yazabiliriz:

$$\text{size} = \log(\text{odds gene normal}) \times \beta_1 + \log\left(\frac{\text{odds gene mutated}}{\text{odds gene normal}}\right) \times \beta_2$$

$\log(\text{odds ratio})$

$\log(\text{odds ratio})$ bize mutasyona uğramış gene sahip olmanın bir bireyin obez olma olasılığını ne kadar artırdığını (veya azalttığını) \log ölçeğinde bize söyler.

$$\text{size} = \log(2/9) \times \beta_1 + \log\left(\frac{7/3}{2/9}\right) \times \beta_2$$

$$\text{size} = -1.5 \times \beta_1 + 2.35 \times \beta_2$$

Burada, lojistik regresyon yaptığımızdan elde ettiğimiz kat sayıları bulduk.

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.5041	0.7812	-1.924	0.0544
geneMutant	2.3514	1.0427	2.255	0.0241


Intercept: $\log(\text{odds gene normal})$, geneMutant: $\log(\text{odds ratio})$

-1.5 intercept değeri'nin -1.9 z value değeri (interceptin 0'dan -1.9 standart hata kadar uzakta olduğunu ifade ediyor) 2'den küçük olduğu için istatistiksel olarak anlamlı değil.

gene Mutant'ın z-value'su 2'den büyük olduğu için istatistiksel olarak anlamlı.


Özetlemek gerekirse;

1. Regresyon için bazı lineer model kavramlarının lojistik regresyona nasıl uygulandığını gördük



(Lojistik regresyonun kat sayılarını $\log(\text{odds})$ eğrisi ile gösterdik.)


2. T testleri için bazı lineer model konseptlerinin lojistik regresyona nasıl uygulandığını gördük



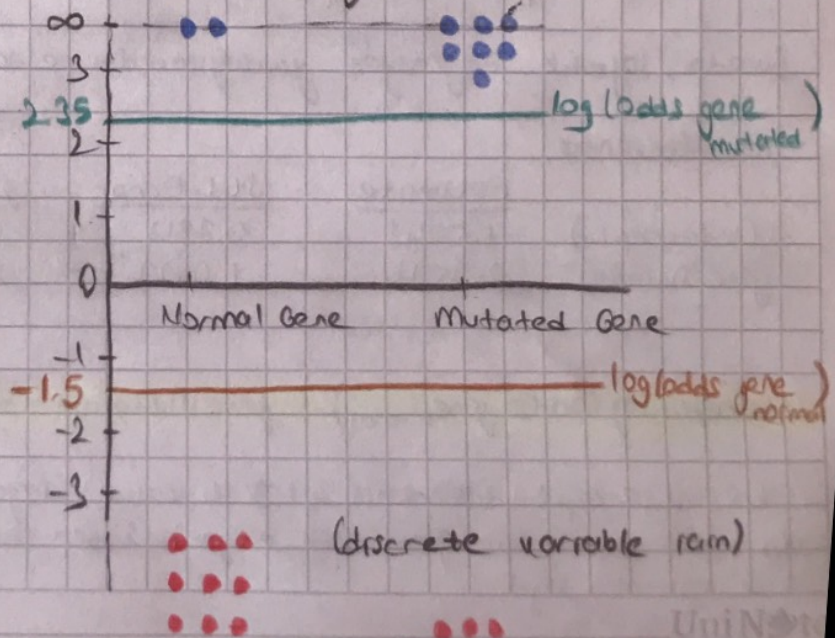
$$\text{Size} = \text{mean}_{\text{normal}} \times \beta_1 + (\text{mean}_{\text{mutant}} - \text{mean}_{\text{normal}}) \times \beta_2$$

$$\text{Size} = \log(\text{odds}_{\text{gene normal}}) \times \beta_1 + \log\left(\frac{\text{odds}_{\text{gene mutated}}}{\text{odds}_{\text{gene normal}}}\right) \times \beta_2$$

Kıyasları kat sayılar açısından lojistik regresyon, kat sayıların $\log(\text{odds})$ açısından olması dışında, lineer modellerle tamamen aynıdır.



(Continuous variable için)



(discrete variable için)

Bu, lineer modellerle yaptığımız şeyleri (multiple regression gibi) lojistik regresyon ile de yapabileceğimizi anlamına geliyor. Burada sadece kat sayıların olacağını log(odds) olduğunu hatırlamamız gerekiyor.