

countbayesie.com/blog/2019/6/12/logistic-regression-from-bayes-theorem

Logistic Regression from Bayes' Theorem

- Lojistik regresyonu bayes teoremindeki nasil elde edilecegimizi,
- Lojistik regresyonun Bayes teoremindeki prior ve likelihoodu verilmisden ogrenemememin bir yolu oldugunu gorecegiz.

Bayes teoremini hatirlayarak olursak;

$$P(H|D) = \frac{P(D|H) \cdot P(H)}{P(D)}$$

Basic lineer modeli hatırlayarak olursak;

$$y = \beta_0 + \beta_1 x$$

modeli hedef degisken y 'nin x carpı β katsayilari arti bir miktar sabit β_0 'in lineer bir kombinasyonu olarak anlasilabilecegini söyleyordu

Lojistik Regresyon Temelleri

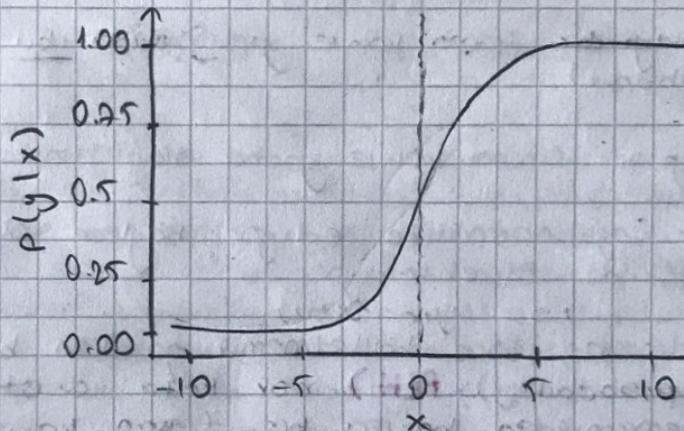
Hepsinin bir temeleme olarak, lojistik regresyon, belli hipotezlerin olasılığını tahmin etmek için verileri kullanmanın yaygın bir yöntemidir. Daha matematiksel olarak konuşursak, bir x girildiğinde var, (bu birinin boyu gibi tek bir değer olabilir veya görüntüdeki pikseller gibi bir vektör olabilir) y hedef deşifreni bu birinci resimde gibi bir aksiyon temsil eder. Lojistik regresyondaki hedefimiz x verildiğinde y 'nın olasılığını öğrenmektedir. Model, y 'nın binary bir aksiyon, 1'in basarı ve 0'in başarısızlık olduğu ve x 'in y aksiyonıyla sonuçlanan veriye karşılık gelmesi bir örnek olduğu örnekler arasında eğitilir. Modeli eğitirkenizde, bir y vektörüne ve satırları training örneklerini, sütunları özellikleri (features) temsil eden bir X matrisine sahibiz.

$$[] = []^{4 \times 4}$$

Buraya kadar her şey yolunda ama burada işler genellikle biraz karışık konusuna hale gelmiş. Bu konuya ilgili x verildiğinde y 'nın olasılığını nasıl hesapladığınızı gösteren aşağıdaki denklem tane gösteriyor.

$$P(y|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

lojistik fonksiyon



Bu ters lojit (inverse logit) veya lojistik fonksiyondur.
 β_0 ve β_1 eğitimi sırasında öğrenileceğimiz parametrelerdir.

Bunun arkasındaki sevgi, genellikle lojistik fonksiyonun çok büyük pozitif sayıları.

1'e ve çok büyük negatif sayıları. 0'a yakını olmaya zorlukları olacaklar ki bu da ihtiyacında olasılıkların nasıl öğrenilemeye çalışıldığıdır. Bu nedenle bu açıklamalar, en çok lojistik regresyon ve Bayes teoremi arasındaki gerekten güzel (ve kullanışlı) bağlantıyı koruyor.

İyi bir fincan kahve yapmak

Mükemmel bir fincan kahve yapmak için farklı miktarlarda kahve, farklı hacimlerde su vb. ile deneyler yapmaya başladım. Mükemmel fincanı olasılıksal olarak nasıl modelleyeceğimi düşünelim.

İlk olarak verilerimi temsil etmek istiyorum. Aynı özelliklerini kullanarak birleştirmeye çalışırken genel bir çok faktör var: Geleneklerin yaşı, eğitimmenin ıriliği, telenin ağırlığı, dökme süresi, suyun sıcaklığı. Hatta elbette, muhtemelen daha da fazla şey bulabileceğiz. Bu yazılıda gerçek veriler hakkında endişelenmemeyeceğim, sadece bu problemi olasılıksal olarak nasıl modelleyeceğimize bakacağım.

Bayesian Breuning (Demleme)

Bir fincan hafiflörken açıklayabileceğimiz tüm olaç seylerin var vektörümüz D olarak düşünelim ve "horika bir fincan kahve" Olan H hipotezimizin olasılığını bilmek istiyorsunuz. Sımdı sadece "Demleme düşenin göz önüne alındığında horika bir fincan kahve alma olasılığı nedir?" sorusuna cevap vermek istiyorsunuz. Yani $P(H|D)$ ’ı bilmek istiyorsunuz. Verilerimizle bir hipotezin olasılığını bilmek istedığımızda Bayes teoremine denebiliriz.

$$P(H|D) = \frac{P(D|H)P(H)}{P(D)}$$

Bu denklemenin her biri parçası icin Bayes terminlerini ve ne onlara geldiklerine bakalım.

- $P(H|D)$, düşenin göz önüne alındığında horika bir fincan kahve yapma olasılığımızdır (our posterior probability).
- $P(D|H)$, yar bir fincan kahve yaptığımda bu durumu sehpı olma olasılığımızdır (likelihood).
- $P(H)$, yar bir fincan kahve yapma olasılığımızdır (prior probability).
- $P(D)$ her seyr normalize ediyor, böylece olasılığımız 0 ile 1 arasıda uygun bir şekilde ölçülüyor.

→ Devam etmeden önce halletmemiz gereken birkaç şey var. Önsel olasılığımız (our prior probability), $P(H)$ çok kafa karıştırıcı değil, sadece genel olarak demlememizden horika bir fincan kahve alacağımızı daır. Bir fincan hafiflörüğün fincanlarını yarısı horikadır, belki sadece 1000’de 118, ama her ikisi şekilde de bunuitemsi ettigideyibudur.

→ $P(D|H)$ ’ı (likelihood) öğrenmek biraz zor, çünkü “yar bir fincan kahve yaptığımda bu durumı kurma ihtimalını ne kadar?”’ı bilmek istiyorsunuz. Bu, problemimiz hakkında öğrenmenin tek tek bir yolu. Ama tam da bu yoldan burada “makinayı öğrenmeli” kullanmak istiyorsunuz. Bu likelihood ian basit bir model bulacağınız, böylece bunu verilerden öğrenecagınız.

→ Geriye sadece verilerimin olasılığını itade eden $P(D)$ kaldı, “kahve demlemek ian bu durum kurulma olasılığı nedir?” Elbette kahve demleme düşen ian neredeyse sonuz olasılık var, bu yüzden bu bir problem. Sunu çözmemesek posterior probability’i ($P(H|D)$) göremeyiz.

Posterior Oddsları Kullandıracak Hipotezleri Karşılaştırma

$P(D)$ 'i, gerçekten bilmemiş gibi gergiyle söylememeniz gerekiyor, sorununuzu yenden verecektir. Bunu öğrenmenin bir yolu var: Su anda sadece bir hipotezi düşünüyoruz, o da bizim bir fincan kahvenizin hırka olması durumu, ama belli ki bu bir alternatif bir durum var.

Sadece kahvenizin hırka olmadığından önceki \bar{H} 'ye dönersek, posteriorları karşılaştırabiliriz ve probleminize $P(D)$ 'e ihtiyaç duymadan bakabiliyoruz. Elde ettiğimiz bir de $P(\bar{H}|D)$ var ve bunun $P(H|D)$ ile oroninal olacaktır.

$$\frac{P(H|D)}{P(\bar{H}|D)} = \frac{P(D|H) P(H)}{P(D|\bar{H}) P(\bar{H})} \cdot \frac{1}{\frac{1}{P(D)}}$$

Tanrı ki $1/P(D)$ hem podya hem de podyada görünüyor, bu yüzden ondan kurtulabiliyoruz. Bu, artık $P(D)$ için endiremememiz gereklidir. Onlarda gelir.

$$\frac{P(H|D)}{P(\bar{H}|D)} = \frac{P(D|H) P(H)}{P(D|\bar{H}) P(\bar{H})}$$

Burada elde ettiğimiz şey, H için posterior odds hesaplama formülüdür. Odds, $P(H|D)$ nın $P(\bar{H}|D)$ 'den kaç kat olası olduğunu söyle eder. Ve $P(H|D) + P(\bar{H}|D) = 1$ olduğu için eninde sonunda oddslarınından $P(H|D)$ 'e geri dönebiliriz. (Bu şekilde birbirinin tamamlayıcısı olmayan iki hipotezi karşılaştırmak doğru olmaz.) Modelimizi öğrenmenin son noktası aslında H örneklerine sahip olmamızdır.

Artık olasılıklar yerine odds hakkında konuşduğumuz için prior odds' umuz olan $P(H)/P(\bar{H})$ ifadesini $O(H)$ olarak ifade edelim. Daha temiz bir formül yazacağ olursak:

$$O(H|D) = \frac{P(D|H)}{P(D|\bar{H})} \cdot O(H)$$

Sorunumuzu çözmek için tanrı bir başlangıç değil. Ardından, bu denklemleri sağ tarafını verilerimizden öğrenmenin bir yoluna ihtiyacımız var.

Lineer Bir Model Bulma

Kullanılabilecek en basit ve hızlı zaman en kullanılıcıl model genellikle lineer bir modeldir.

$$y = \beta x + \beta_0$$

Bu sadece, y 'nın bozı β sabit oronlarında batı betap kesimeler ile ortaya ve oradığı onlara gelir. Bu, seyttere bakmanın basit bir yoludur, ancak elimizde veri varsa, bunun için en uygun parametreyi doğrusal regresyon ile öğrenebiliriz. Ne yazık ki, kahve sorununa suındaki olasılıksız değişimimiz böyle bir şeye benzemiyor... hemz.

Kurtarma i̇am: Log Dönüşümü

Olasılık problemindeki odds formunun içinde sadece carpmalar ve bölmeler olduğunu fark edebilirsiniz, bu da genel bir lineer olumsundan biraz uzakta olduğunu gösteriyor. Ancak bunu doğru birimde etde etmek için çok faydalı bir trick var: basittər log dönüşümü yapabilmek. 10 tabanındaki sayılar hakkında sevgiler yapmak daha kolay olduğu için simdirlik \log_{10} kullanacağız.

$$O(HID) = \frac{P(D|H)}{P(D|\bar{H})} \cdot O(H)$$

$$\log(O(HID)) = \log_{10}\left(\frac{P(D|H)}{P(D|\bar{H})} \cdot O(H)\right)$$

$$\log(O(HID)) = \log_{10}\left(\frac{P(D|H)}{P(D|\bar{H})}\right) + \log_{10}(O(H))$$

Dikkat ederek simde bir lineer denklemini var. $O(H)$ 'ın yerine vektörel formda hala bağlı olmadığını da dikkat edin, tipki lineer modelde olduğu gibi şu sadece bir sabittir ve X 'e bağlı değildir. Yani lineer modelimiz için şunu söyleyebiliriz:

$$\beta_0 = \log_{10}(O(H))$$

Veya β_0 , prior odds'un logudur.

$$\begin{matrix} D \rightarrow x \\ \log_{10}\left(\frac{P(D|H)}{P(D|\bar{H})}\right) \rightarrow \beta x \end{matrix}$$

Simdi modelimin kalbine geliyorsun. Pürüz göz atarak, log likelihood oranının basittər D 'nın lineer bir fonksiyonu olduğu şeklindeki bağıntılılığını varsayımlı yapmaya devam edeceğiz. Örneğin, belki de varyasyonun sıklığında bir azalma log-likelihood'un lineer olarak azalmaması neden olur. Bu konuya bir bakallık, çünkü bir şeyin olasılığını 0.01'den 0.1'e artırmak olasılığını 0.09'luk doğrusal bir artış değil, artel bir artış olur! Dolayısıyla olasılıkları doğrusal bir şekilde modelllemek istiyorsak log dönüşümü yapmayı yerler arısından tercih etmeliyiz.

$$\begin{aligned} \log(0.01) &= -2 \\ \log_{10}(0.1) &= -1 \\ (10^{-1}) \text{ artı } & \end{aligned}$$

Bu varsayımlı yaparsak, likelihood oranını βD olarak modelleyebiliriz. Ve simdi problemindeki genel bir lineer çözümümüz var. Burada $\log(O(HID))$ 'yi $\log(O(HID))$ olarak göstericeğiz.

$$\log(O(HID)) = \beta D + \beta_0$$

Bu lineer form ile log formunda verinin lineer bir fonksiyonu olarak likelihood oranını ve prior oddsı öğrenebiliriz. Lojistik regresyonu lineer bir model yapan şey budur, Bunda likelihoodun $P(D|H)$ 'in逆の値 olarak ifade edilebilir. Ancak bu doğrusal ilişkili ifadeyi kullanmak için ciktimizi log odds'a dönüştürmemiz gerekiyordu.

Where we are so far: probabilities, odds and log odds

Eşdeğer kriter neler olduğunu bildiğimizde olsa olmazsa bunu bire özetleyelim. $P(H|D)$ 'i bilmek istedik ki bu, D denleme durusunu gösteren olasılığın da bir kahve almak olasılığının ifade ettiğidir. Bayes teoremiyle $P(D|H)$ 'yi her zamanın bir yolunu bulamazsa da, bu sorunu neredeyse çözebildik. Bu, yalnızca $P(H|D)$ 'e bakmak yerine kahvenin horka olması olasılığıyla olasma olasılığı H 'yı karşılaştırır. odds or $O(H|D)$ bakanızın gerektiği anlamanı getir. Odds, bir hipotezin değerine ne kadar muhtemel olduğunu orantısal olarak bize sonuçları verecektir:

- $O(H|D) = 10$ kahvenin işe olma ihtimalının işe olasma ihtimalinden en az 10 kat daha fazla olduğu anlamına gelir.
- $O(H|D) = 1/10$ kahvenin işe olasma olasılığının 10 kat daha fazla olduğu anlamına gelir.

Odds formattının asimetrik olduğunu dikkat edin, çünkü hipotezimiz iken konular boyadıkça sonuç sonuca doğru boyar ve hipotezimizde konular boyadıkça odds 0'a dayanır.

Oddsı $\log_{10} O(H|D)$ 'a çevirdiğimizde bu asimetriyi düzeltiriz:

- $\log_{10} O(H|D) = 1$ horka kahvenin 10 kat daha olası olduğu anlamına gelir
- $\log_{10} O(H|D) = 2$ horka kahvenin 100 kat daha olası olduğu anlamına gelir
- $\log_{10} O(H|D) = -1$ horka kahvenin 10 kat daha olasılığı olmadığı anlamına gelir
- $\log_{10} O(H|D) = -2$ horka kahvenin 100 kat daha olasılığı olmadığı anlamına gelir

Bu yüzden, problemimize bakanızın bize güzel bir lineer yol vermemenin yanı sıra, problemimizi log odds ile çercevelmek, sonuçları yorumlamaya çalıştığımızda aslında çok mantıklı gelir.

Modelimizi Öğrenme Juru

Problemimizin temelde lineer regresyonu benzeren güzel bir lineer formumuz var.

$$y = \beta x + \beta_0$$

Elinde bir türümüzde problemimizdi dilersek herhangi bir linear regression probleminde yaptığımiz gibi en klasik kriterler en çok indirek (minimum least squares) uygulayabiliyoruz. Bu yaklaşımın, bily oldugu gibi kullandığımızda ve verilerimizin değerlerine bağlı olarak log oddsun ortasını veya otalgının varlığından rıza verilemeli dönüştürmemiz gerekiyor. Ancak hedef degrıskenmişin nasıl dönüştürüleceğini dünmemiz gerekiyor. Üstende belirttiğimiz hedef yani zaten $P(H|D)$ formunda vermişimizdir. Başarılı olan durumlar rıza $P(H|D) = 1$ olduğunu ve başarısız olan durumlar rıza $P(H|D) = 0$ olduğunu biliyoruz. Lineer modelimizi eğitmek rıza önce hedef verilemeli, log odds formunu dönüştürmemiz gerekiyor.

Ama burada can sıkıcı bir sorun var! Bir olasılık oddsı dönüştürmek rıza en basit kurallı takip edebilir mi?

$$O(H) = \frac{P(H)}{1 - P(H)}$$

Ancak burada bir sorun olduğunu görebiliyoruz çünkü olasılıklar mutlak 1 veya 0'dır. Pozyitif caseller rıza odds tonumuz olsa 1/0'dır. Ve negatif durum rıza oddsun logunu almaktı istedigimizde bu sorunu çözerek bize yapamaztı çünkü bunlar 0/1 olacak ve log 0 da onlamaz.

Log Odds Tekrar Olasılıklara Girmek : Ters Logit (Inverse logit)
Gözlemevi sınırların bir ekilde yakını ve herhangi tam olasılık oraya ulaşamamak da değerler bir sey olgendir. Olasılık problemlimizde merkezinde linear bir model var. Hedef degrıskenmiş dönüştürmeyecez, ancak bu linear modelin kendisini tekrar bir olasılık dönüştürbiliriz, o zaman gözlemevi bulmuş olacağız.

Bu gözlemevi dercede kolay. Yaptığımız her seyi geri almak için gerekiyor, ama bu sefer bunu linear modelde yapmışız. Modelimiz su anda log odds cinsinden yazılmıştır, bu yüzden yapmak gereken ilk sey log dönüştürme işi olmaktadır. Bunu linear denkleminin 1/b, kuvvetini olarak yapabiliriz.

$$\log(O(H|D)) = \beta D + \beta_0 \rightarrow O(H|D) = 10^{(\beta D + \beta_0)}$$

Bu oldukça kolaydı! Elinde sadece oddsı olasılıklara çevirmemiz gerekiyor, bu olasılıkları oddsı dönüştürmek kadar kolay. Bu kurallı kullanabilelim!

$$P(X) = \frac{O(X)}{1 + O(X)}$$

$$O(X) = \frac{P(X)}{1 - P(X)}$$

Bunu yaparak sunu görebiliyoruz:

$$P(H|D) = \frac{10^{(\beta D + \beta_0)}}{1 + 10^{(\beta D + \beta_0)}}$$

$$\begin{aligned} O(X) - O(X) \cdot P(X) &= P(X) \\ O(X) &= P(X)(1 + O(X)) \\ \frac{O(X)}{1 + O(X)} &= P(X) \end{aligned}$$

Hedef degerlerimizde döner taremedigimiz tam $\beta D + \beta_0$ 'i döner tarmak zorunda kaldık, ama sonun degeri guncu her ikisi sekilde de aynı etkije sahip ve bu sefer sonucularinin (outcomes) mutlak 1'ler ve 0'lar oldugu gercegini valdribiliriz.

Bunu daha once ve matematiksel olarak daha kabul edilebilir kilmak için yapabilecegimiz iki basitleştirmeye daha vor. ilk olarak, hicbir ciddi matematiksel logis'u kullanmam, bunun yerine ln'ı tercih eder. Bu yoldan bu 10'u e'ye degritlenmemi gerekir. Sonrakimizde taban 10'da tutmamla yillik dael bir durumumuz yok, bu yoldan bu degritlikte hicbir sonun yok, etkiler ayni olacak.

$$P(H|D) = \frac{e^{(\beta D + \beta_0)}}{1 + e^{(\beta D + \beta_0)}}$$

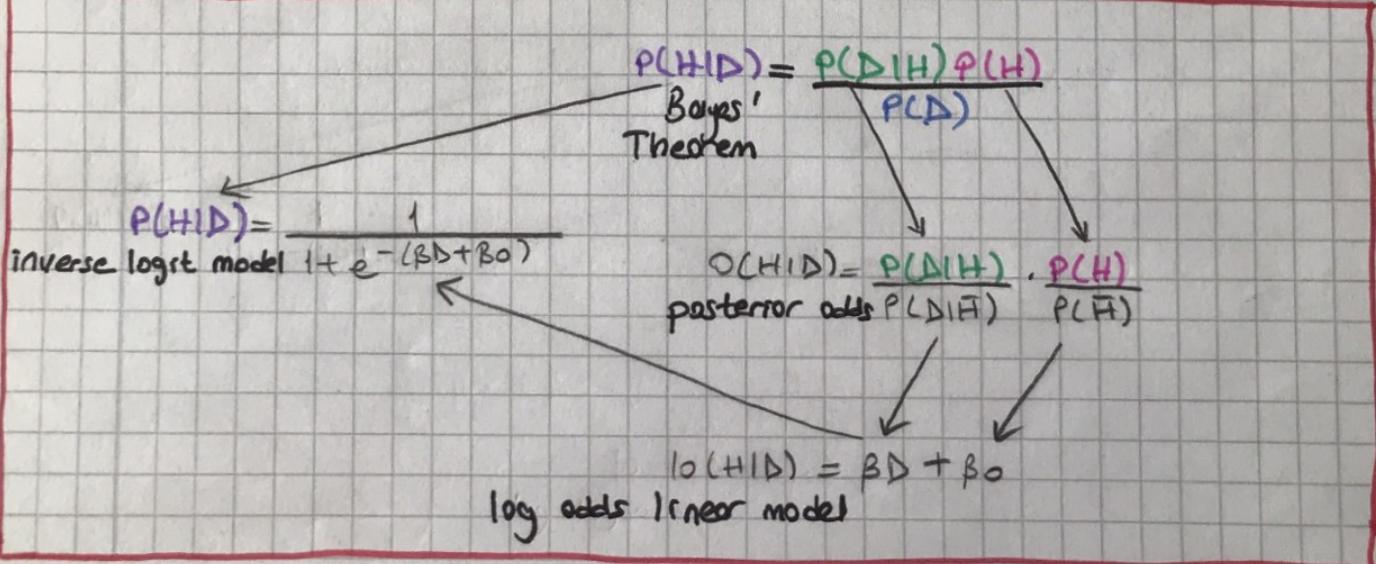
Ve aynı zamanda olukca uygun bir sekilde ontaya aliyor:

$$\frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}}$$

Bu, son denklemlerimizde baslangicta gordugumuz gecmis formule döner tarebilecegimiz anlamina gelir.

$$P(H|D) = \frac{1}{1 + e^{-(\beta D + \beta_0)}}$$

Burada, bu formülün log oddsu tekrar oluslugor döner tarmenin bir yolu oldugunu goruyoruz. Bu, elbette, kelimenin tam anlamıyla "inverse logit" in ne anlam geldegidir, "logit" "log odds" fonksiyonudur. Logit fonksiyonu olasılıkları altı ve bunları log odds döner tarmar, "inverse logit" log odds altı ve onları olasılıklara döner tarmar.



Logistik regresyon türetmekten elde ettigimiz temel anlayışlardan biri, logistik regresyonun nasıl lineer bir model olduğunu çok açık bir şekilde gösterebilir. Bayes teoremi problemimizi Bayes teoremi olarak modelliyoruz, onca hipotezimiz için verilen veritemiz likelihoodini ve prior probabilitesini belirliyoruz. Bundan verilenden öğrenebilmek istiyorsak ve bunda yapmak için en uygun olabilecek hipotezinin log oddsını de vermiş D olsunsa, lineer bir ilişkisi olduğu gibi bağıntılı bir yaklaşımın bulunuyoruz.

Tüm bunları gözden geçirerek sonra, Bayes teoremi ve lineer regresyonun temellerinden başlayarak bunu istedigimiz forman üzerinden olusturabiliyoruz. Artık inverse logit kullanarak β ve β_0 'ı öğrenmek için bir model eğitezelim.

Fonksiyonlar

Bu, bir dincin kahve yapmak için Oldukça karmaşık bir yol olsa da, Bayes teoremi ile logistik regresyon arasındaki ilişkisi öğrenmek, logistik regresyon nasıl çalıştığını daır oldukça güzel birlerden sağlıyor.

Ayrıca genelleştirilmiş lineer modelin (generalized linear model) genenin de biraz teknik bir bakışta Buna da yaptığımızın büyük bir kısmı, lineer bir modeli denetirebilecek bir fonksiyon, bu durumda ters logit bulmakta. Bu da eğitirme ile bunun, lineer modelin diğer denemelerine dayalı olarak çeşitli diğer regresyonları gerçekleştirmek için genelleştirileceğini gösterir.