


Youtube - Statquest with Josh Starmer


Logistic Regression Details Pt 2: Maximum Likelihood

2 Bu dalgali ağığın verilere en iyi şekilde uyması için nasıl optimize edildiğinden bahsedebiliriz.



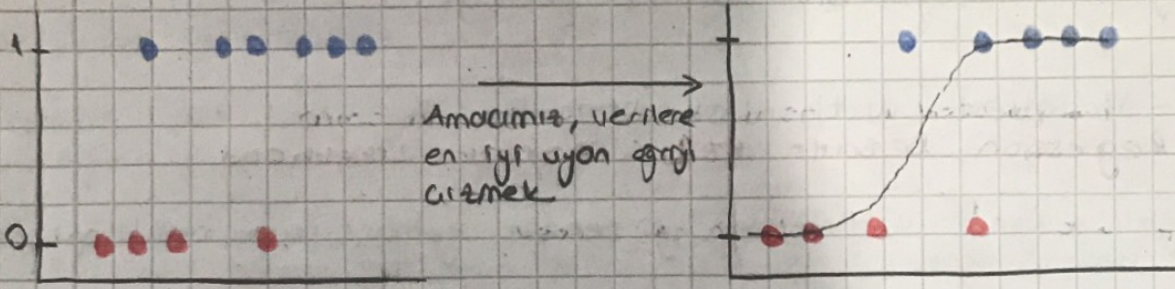
Logistic regresyonun lineer regresyonla benzer mantıkta olduğundan fakat logistic regresyonun olasılıklarla ifade edilmesinden bahsetmiştik. Lineer regresyondaki gibi katsayılarını grafik üzerinde görebiliyorduk doğrusal bir eğri elde edebilmek için olasılık değerlerini $\log(\text{odds})$ cinsine çeviriyoruz. Bu eğriyi maximum likelihood ile getiriyoruz.

Lineer regresyonda eğriyi nasıl getiriyorduk?




- Verilerimiz var en kötü şekilde.
- Bu verilere least-squares (en küçük kareler) yaklaşımıyla bir line fit ediyoruz.
- Diğer bir deyişle veriler ile line arasındaki uzaklıkları (residuals) ölçüyoruz. Bunların karesini alıyoruz (ki negatif değerler pozitif değerleri götürmesini) ve hepsini topluyoruz.
- Ve line'i bir ölçüde döndürüyoruz. Tekrar residuals'ları ölçüyoruz, karelerini alıyoruz ve onları topluyoruz.
- Bize en küçük sum of squared residuals'ları veren (ki bu da the least squares diyor) line'i seçüyoruz.

Logistic Regresyonda Nasıl Yapıyoruz?




Logistic regresyonda y eksenindeki obezite olasılığı (probability of obesity) - log (odds of obesity) ye çevriyoruz.



Tek sorun, dönüştürmün hem verileri pozitif ve negatif sonuçluğa itmesidir. Bu da, residualların pozitif ve negatif sonuçluğa ept olduğu anlamına gelir. Bu da en iyi line'i bulmak için least-squares'i kullanamamıza anlamına gelir. Bunun yerine maximum likelihood kullanıyoruz.


Yapacağımız ilk şey, original veri noktalarını aday line'a göstermek. Bu, her örneğe bir aday log (odds) değer verir.



Diğer bir deyişle (1) noktasının log(odds)'u -2.1, (2) noktasının log(odds)'u -1.4.

Ardından bu formüle kullanarak aday log (odds)'u aday olasılıklara (probabilities) dönüştürürüz.

$$p = \frac{e^{\log(\text{odds})}}{1 + e^{\log(\text{odds})}}$$



Original Line

$p = \frac{e^{\log(\text{odds})}}{1 + e^{\log(\text{odds})}}$ eşitliği $\log\left(\frac{p}{1-p}\right) = \log(\text{odds})$ eşitliğinin her iki tarafını logaritma ile alarak elde edilen bir eşitlik.

$\log\left(\frac{p}{1-p}\right) = \log(\text{odds}) \rightarrow$ her iki tarafın da assını alıyoruz.

$\frac{p}{1-p} = e^{\log(\text{odds})} \rightarrow$ her iki tarafı $1-p$ ile çarpıyoruz.

$p = (1-p) \cdot e^{\log(\text{odds})} \rightarrow (1-p)$ 'yi $e^{\log(\text{odds})}$ ile çarpıyoruz.

$p = e^{\log(\text{odds})} - p e^{\log(\text{odds})} \rightarrow p e^{\log(\text{odds})}$ 'u karşı tarafa geçiriyoruz.

$p + p e^{\log(\text{odds})} = e^{\log(\text{odds})} \rightarrow p$ paranteze alıyoruz.

$p(1 + e^{\log(\text{odds})}) = e^{\log(\text{odds})} \rightarrow$ her iki tarafı $(1 + e^{\log(\text{odds})})$ 'e bölmeye.


$$p = \frac{e^{\log(\text{odds})}}{1 + e^{\log(\text{odds})}}$$

1) noktası için bu formülü uygularsak;

$$p = \frac{e^{-2.1}}{1 + e^{-2.1}} = 0.1$$

0.1 değeri bize dalgali eğride noktanın nereye konacağı bilgisini verir. Tüm noktalar için aynı işlemi tekrarlarız.

2) Simili veriler için de likelihoodu hesaplamak için gözlemlenen durumu (özet veya değil) kullanıyoruz.



Özet olan foristen başlıyoruz. (a) foristen likelihoodu (y eksenini kesen değer), 0.49. Yani, bu foristen likelihoodu, predicted probability ile aynı.


Bu case'de probability eğrinin altında kalan alan ile değil de y eksenindeki değeri hesaplanıyor, bu yüzden likelihood ile aynı.

(b), (c), (d), (e) noktalarının likelihoodu sırasıyla 0.9, 0.91, 0.91 ve 0.92.

Obes olan tüm bireylerin likelihoodu her bir likelihoodun çarpımı olarak hesaplanıyor.

$$\text{Verilerin likelihoodu} = 0.49 \times 0.9 \times 0.91 \times 0.91 \times 0.92 \times \dots$$

2) Şimdi obes olmayan bireylerin likelihoodunu hesaplayalım.



Not: Obes olma olasılığı ne kadar düşükse, obes olmama olasılığı da o kadar yüksektir.

Bu yüzden, bu bireyler için;

$$\text{likelihood} = (1 - \text{bireyin obes olma olasılığı})$$

(x) noktesi için obes olma olasılığı 0.9, bu yüzden obes olmamanın olasılığı ve likelihoodu $1 - 0.9$

(y) noktesi için obes olma olasılığı 0.3, bu yüzden obes olmamanın olasılığı ve likelihoodu $1 - 0.3$

(z) ve (k) noktaları için obes olma olasılığı 0.01 bu yüzden obes olmamanın olasılığı ve likelihoodu $1 - 0.01$

Bu değerleri de tüm verilerin likelihoodunu hesapladığımızı eşitliğe dahil ediyoruz.

$$\text{Verilerin likelihoodu} = 0.49 \times 0.9 \times 0.91 \times 0.91 \times 0.92 \times (1 - 0.9) \times (1 - 0.3) \times (1 - 0.01) \times (1 - 0.01)$$

Verilerin likelihoodunu her bir bireyin likelihoodunu çarparak hesaplamak mümkün olsa da istatistikçiler likelihoodun logunu hesaplamayı tercih ederler.


Her ikisi de mümkün, çünkü likelihoodu maksimize etmekle, likelihoodun logunu maksimize etmek aynı şeydir.

Şimdi Likelihoodun logunu aldığımızda her bir likelihoodun logunu alıp topluyoruz.

$$\begin{aligned} \log(\text{verilerin likelihoodu}) &= \log(0.49) + \log(0.9) + \log(0.91) + \log(0.91) + \log(0.92) + \\ &\quad \log(1 - 0.9) + \log(1 - 0.3) + \log(1 - 0.01) + \log(1 - 0.01) \\ &= -3.77 \end{aligned}$$

Dolaylı olarak verilen noktaların likelihoodu -3.77 çıktı. Bu da original ln da (log(odds)) log-likelihoodun -3.77 olduğu anlamına geliyor. (2. kısım)


Original line'i rotate ediyoruz ve verileri üzerine yansıtıp $\log(\text{odds})$ 'ları olasılıklara dönüştürerek log-likelihood hesaplıyoruz.



$$\log(\text{verilerin likelihoodu}) = \frac{\log(0.22) + \log(0.4) + \log(0.8) + \log(0.89) + \log(0.92) + \log(1-0.6) + \log(1-0.2) + \log(1-0.1) + \log(1-0.07)}{2} = -4.15$$

Bu line ilki kadar iyi değil.

Bu şekilde $\log(\text{odds})$ line'ini döndürmeye ve verileri üzerine yansıtmaya $\log(\text{odds})$ 'ları olasılıklara dönüştürüp log-likelihood hesaplamaya devam ediyoruz.



Maksimum olasılığa (maximum likelihood) sahip line'i bulan algoritma oldukça akıllıdır. Line'i her döndürdüğünde, bunu log olasılığı arttıracak şekilde yapar. Böylece algoritma birkaç döndürmeden sonra en uygun yunu bulabilir. Burada, likelihood en üst düzeye çıkaran bir line elde edene ve bu en uygun olan olarak seçilir.

Bunun sonrasında bu line'in faydalı bir modeli temsil edip etmediğini bilmek istiyoruz ve bu, bir R^2 değeri ve p-value'yi içerir. Bu anlamına gelir.